

先手算，再让程序运行

配套工作台AI小实验与Python标准库实训。这里使用自编合成数据，题目和图均可复查。

本页任务： $y = 2x + 1$ ，模型预测为 $w \cdot x + b$ 。约定残差 $r = w \cdot x + b - y$ 。初始 $w = b = 0$ ，学习率0.1，损失为平方误差和除以2m。先填写残差与梯度，再看第3页答案。

x	y	残差 r	$r \cdot x$	r^2
-2	-3			
-1	-1			
0	1			
1	3			
2	5			

初始损失L、dw、db分别是多少？

同一份旧参数下，新w、b分别是多少？损失会下降吗？

若去掉损失里的1/2，要保持同样更新，学习率应怎样改？

追踪一个样本的前向与反向

为便于手算，本页用 $2 \rightarrow 2$ ReLU $\rightarrow 2$ 的小例子；运行实训的分类网络有8个隐藏单元。

输入 $x=[1,-2]$ ；真实标签 $y=1$ （类别从0开始）。

$W1=[[1,0.5],[-1,1]]$ ， $b1=[0.5,0]$ 。

$W2=[[2,-1],[-1,1]]$ ， $b2=[0,0]$ 。

矩阵约定： $W[\text{输出}][\text{输入}]$ 。 $a=W1*x+b1$ ； $h=\text{ReLU}(a)$ ； $z=W2*h+b2$ ； $p=\text{Softmax}(z)$ 。

1. 求 a 、 h 、 z 和两个概率 p 。哪个隐藏单元不激活？

2. 交叉熵对分数的梯度为 $p\text{-onehot}(y)$ 。求 dz 、 $dW2$ 、 $db2$ 。

3. 用旧 $W2$ 把梯度传回： $dh=W2\text{的转置}*dz$ 。经过ReLU后求 da 、 $dW1$ 、 $db1$ 。

思考：如果先更新 $W2$ 再求 dh ，还能把这一组梯度当成旧模型的完整梯度吗？

对照答案，核查每一个因子

数值由同一实训模块计算；先看残差符号、平均因子和矩阵方向，再看小数。

回归：初始残差 $[3, 1, -1, -3, -5]$ ，平方和45， $m=5$ ，所以 $L=4.5$ 。 $dw=-4$ ， $db=-1$ ；新 $w=0.4$ 、 $b=0.1$ ；新损失2.965。去掉1/2后梯度加倍，学习率应减半。

网络前向： $a=[0.5, -3.0]$ ， $h=[0.5, 0]$ ， $z=[1.0, -0.5]$ 。 $p \approx [0.817574, 0.182426]$ ，交叉熵 ≈ 1.701413 。

$dz \approx [0.817574, -0.817574]$ ； $dW2 \approx [[0.408787, 0], [-0.408787, 0]]$ ； $db2=dz$ 。

$dh \approx [2.452723, -1.635149]$ 。第2单元 $a < 0$ ，故 $da \approx [2.452723, 0]$ 。

$dW1 \approx [[2.452723, -4.905447], [0, 0]]$ ； $db1 \approx [2.452723, 0]$ 。

这里只有一个样本，不再额外除以大于1的批量大小。多样本时先求和，再统一除以 m 。所有梯度都在更新任何参数之前算完。

两个数值保护与一条独立检查


Softmax先减最大分数再取指数；交叉熵用 $\log\text{-sum-exp}$ 计算，不用随意裁剪概率隐藏大损失。中心有限差分比较独立数值导数，但应避开ReLU的0点折线。

有限差分： $(L(\theta + \epsilon) - L(\theta - \epsilon)) / (2 * \epsilon)$ 。它核对的是选定位置附近的导数，不证明标签、数据划分或新场景能力都正确。

代码位置：`math_lab.py`中的`forward`、`loss_gradient`、`gradient_check`；验证命令：`python practice/test_math_lab.py`。


用图看见模型表示能力

固定种子2025的400个合成簇样本：训练240 / 验证80 / 测试80。均值与标准差只来自训练。



蓝点是真实类别0，棕点是真实类别1；背景是类别1的模型概率。两个轴都是原始坐标。测试点在训练结束后展示，未用于选参数。

平均交叉熵：蓝色线性模型 / 棕色网络；实线训练 / 虚线验证



线性模型：验证选中第598轮；测试50.0%，交叉熵0.692655。

ReLU网络：验证选中第600轮；测试100.0%，交叉熵0.006009。

一条直线无法分开两对对角簇；隐藏层可形成分段边界。简单合成样本上的高分不等于真实应用能力，不能与digits实验的指标混用。

合上代码，独立回答12个问题

先用自己的话写结论与依据，再翻到下一页。答案看起来熟悉，不等于能独立解释。

1. 回归初始损失为什么是4.5？新参数与新损失分别是多少？

2. 去掉损失中的1/2时，同样更新幅度对应怎样的学习率？

3. 给所有Softmax分数加10000，为什么数学概率不变而直接exp可能出错？

4. $p=[0.9,0.1]$ 、真实类别1时，两个分数梯度是什么？

5. 为什么分数梯度之和为0？它对应哪种不变性？

6. ReLU在负、正、0区间的导数怎样理解？

7. 先更新输出权重再计算隐藏梯度，会破坏什么约定？

8. 同一批样本复制两遍，平均损失与平均梯度为何不变？

9. 测试均值与训练均值不同，能否合并全数据拟合标准化器？

10. 第600轮训练损失更低，是否一定应替代验证选中的第598轮？

11. 梯度检查通过，是否证明标签、划分与泛化都正确？

12. 80张简单合成测试样本全对，能否宣称实际应用准确率100%？

核对理由，而不只核对数字

把你遗漏的条件改写成自己的错题卡。12张配套文本可在工作台批量录入。

1. 平方和45除以10得4.5； $dw=-4$ 、 $db=-1$ ；新 $w=0.4$ 、 $b=0.1$ ， $L=2.965$ 。
2. 梯度加倍，学习率减半；学习率数值必须与损失约定一起解释。
3. 分子分母的指数公共因子可约掉。机器 $\exp(10000)$ 会溢出，先减最大分数。
4. $[0.9, -0.9]$ 。下降更新降低错误类分数并提高真实类分数。
5. 概率和与one-hot和都是1；对应全部分数同加常数时概率不变。
6. 负区间为0，正区间为1；0处没有唯一普通导数，实现需约定。
7. 完整梯度应来自同一份旧参数；混用新旧权重不再对应这次旧模型梯度。
8. 分子与样本数同时翻倍，比值不变。若翻倍，检查平均因子。
9. 不应把测试统计用于拟合预处理；仅训练侧拟合，再统一变换。
10. 不一定。训练损失降低不保证验证更好；按预先约定的验证选择，测试不选轮次。
11. 不能。只验证选定输入/参数附近的导数；研究设计与新场景还需独立检查。
12. 不能。只描述这次分布的80个样本；保留样本量、分布与实际任务差异。

来源与复现

题目、合成数据、代码与图为本项目自编。回归与分类基础可参考Stanford CS229讲义。真实digits数据的UCI作者、许可、随机划分与限制见工作区“数字分类模型说明.md”；本册没有把它当作合成样本。

[Stanford CS229 notes / 2023](#)

留下一次可复查的实验

先复制原输出，再只改一个条件。建议将这一页与JSON报告放在一起。

问题与运行前预测：

固定条件：数据、种子、模型、预处理：

这次唯一改变的条件：

梯度检查结果与训练曲线：

验证选择与理由：

最终测试指标、混淆矩阵与误判：

与预测不同的地方：

目前不能得出的结论：

下一次要验证的问题：

运行：python practice/run_lab.py。报告、实际样本、参数与曲线存于practice/output；复习文本在examples/AI实训复习卡.txt。普通网页使用无需Python。